

Resumen para el equipo — Modelos de rendimiento de cebada

Superciclo Classic ML · Reto AgroCebada FIRA 2026 · Equipo Los Vochos

Este documento resume, en lenguaje claro, qué familias de modelos y qué conjuntos de datos funcionaron mejor tras probar de forma sistemática todas las tablas curadas (1024) con varios algoritmos clásicos. La validación oficial deja fuera un municipio completo en cada ronda (leave-one-municipio-out). La métrica principal es el error RMSE en toneladas por hectárea: **más bajo es mejor**.


Mensaje clave

El mejor resultado afinado obtiene un RMSE de **0.533 t/ha** (explica ~61% de la varianza en validación), frente a una media ingenua por estado de **1.084 t/ha**. Ajustar hiperparámetros apenas mejoró 0.009 t/ha. **Veredicto:** Classic suficiente para entrega. Conviene congelar un candidato Classic para entrega y dashboard, no seguir barridos masivos de modelos.

Ganador propuesto: LightGBM (árboles con boosting) sobre un dataset de Solo ciclo 2025, Ubicación: longitud y píxel climático, y Reto + nitrógeno + edafología.

1. Mejores familias de modelos


Para cada familia tomamos su mejor combinación de datos. LightGBM domina con claridad; los lineales (Ridge) siguen siendo útiles como referencia interpretable. Elastic Net quedó por debajo de los baselines en este diseño y no se recomienda.



Familia	RMSE	MAE	r²	Tipo de datos (resumen)
LightGBM	0.542	0.379	0.59	Solo ciclo 2025; Ubicación: municipio y longitud; Reto + nitrógeno + edafología
Ridge	0.576	0.415	0.54	Solo ciclo 2025; Ubicación: longitud y píxel climático; Reto + nitrógeno + CIC
Hist. boosting	0.623	0.454	0.46	Multi-año (2022–2025); Ubicación: estado, municipio, longitud y píxel climático; Reto + ni
Bosque aleatorio	0.664	0.461	0.39	Multi-año (2022–2025); Solo longitud; Reto + nitrógeno + limo
Elastic Net	1.138	1.047	-0.80	Solo ciclo 2025; Solo longitud; Solo datos del reto

2. Top 10 — datos solo del reto (originales)


Carril sin SoilGrids ni edafología INEGI. Útil si la entrega debe basarse únicamente en el dataset oficial del reto.



#	Modelo	RMSE	MAE	r ²	Descripción del dataset
1	LightGBM	0.550	0.385	0.58	Solo ciclo 2025; Solo longitud; Solo datos del reto
2	LightGBM	0.551	0.387	0.58	Solo ciclo 2025; Ubicación: longitud y píxel climático; Solo datos del reto
3	LightGBM	0.556	0.393	0.57	Solo ciclo 2025; Ubicación: municipio y longitud; Solo datos del reto
4	LightGBM	0.556	0.393	0.57	Solo ciclo 2025; Ubicación: municipio, longitud y píxel climático; Solo datos del reto
5	LightGBM	0.582	0.418	0.53	Solo ciclo 2025; Ubicación: estado, longitud y píxel climático; Solo datos del reto
6	LightGBM	0.582	0.418	0.53	Solo ciclo 2025; Ubicación: estado, municipio, longitud y píxel climático; Solo datos del reto
7	LightGBM	0.583	0.419	0.53	Solo ciclo 2025; Ubicación: estado y longitud; Solo datos del reto
8	LightGBM	0.583	0.419	0.53	Solo ciclo 2025; Ubicación: estado, municipio y longitud; Solo datos del reto
9	LightGBM	0.592	0.447	0.51	Multi-año (2022–2025); Ubicación: longitud y píxel climático; Solo datos del reto
10	LightGBM	0.592	0.446	0.51	Multi-año (2022–2025); Ubicación: municipio, longitud y píxel climático; Solo datos del reto

3. Top 10 — datos extendidos (reto + externos)



Carril que añade variables de suelo (SoilGrids y/o INEGI). En el superciclo aportan una mejora pequeña pero consistente respecto al solo-reto.



#	Modelo	RMSE	MAE	r ²	Descripción del dataset
1	LightGBM	0.542	0.379	0.59	Solo ciclo 2025; Ubicación: municipio y longitud; Reto + nitrógeno + edafología
2	LightGBM	0.543	0.383	0.59	Solo ciclo 2025; Ubicación: longitud y píxel climático; Reto + nitrógeno + edafología
3	LightGBM	0.543	0.384	0.59	Solo ciclo 2025; Solo longitud; Reto + nitrógeno del suelo (SoilGrids)
4	LightGBM	0.544	0.384	0.59	Solo ciclo 2025; Solo longitud; Reto + nitrógeno + edafología
5	LightGBM	0.545	0.383	0.59	Solo ciclo 2025; Ubicación: municipio, longitud y píxel climático; Reto + nitrógeno + edafología
6	LightGBM	0.545	0.385	0.59	Solo ciclo 2025; Ubicación: longitud y píxel climático; Reto + nitrógeno del suelo (SoilGrids)
7	LightGBM	0.546	0.382	0.59	Solo ciclo 2025; Solo longitud; Reto + nitrógeno + edafología + limo
8	LightGBM	0.546	0.379	0.59	Solo ciclo 2025; Ubicación: longitud y píxel climático; Reto + nitrógeno + edafología + limo
9	LightGBM	0.546	0.382	0.58	Solo ciclo 2025; Ubicación: municipio y longitud; Reto + nitrógeno + edafología + limo
10	LightGBM	0.548	0.383	0.58	Solo ciclo 2025; Ubicación: municipio y longitud; Reto + nitrógeno + limo



4. Cómo se comportan los mejores en validación


Cada parcela de entrenamiento se predice exactamente una vez cuando su municipio queda fuera del aprendizaje. Abajo: comparación de métricas, mapa de calor de predicciones y contraste realidad vs predicción del ganador.



5. Real vs predicho (modelo ganador)


Si los puntos se acercan a la diagonal, el modelo está bien calibrado. El histograma de errores muestra si tiende a sobre- o sub-estimar.





6. Predicciones sobre las 59 parcelas ocultas

Estas parcelas no tienen rendimiento observado en el reto. El gráfico muestra la predicción del modelo ganador (ordenadas de menor a mayor). No hay etiqueta real para comparar aquí; la calidad se respalda en la validación anterior.



Muestra: las 12 predicciones más altas

Parcela	Municipio	Estado	Predicción (t/ha)
AGC_142	Chignahuapan	Puebla	4.93
AGC_095	Chignahuapan	Puebla	4.84
AGC_191	Chignahuapan	Puebla	4.78
AGC_143	Chignahuapan	Puebla	4.70
AGC_011	Chignahuapan	Puebla	4.70
AGC_136	Chignahuapan	Puebla	4.68
AGC_094	Chignahuapan	Puebla	4.67
AGC_076	Chignahuapan	Puebla	4.66
AGC_028	Chignahuapan	Puebla	4.64
AGC_016	Chignahuapan	Puebla	4.59
AGC_154	Chignahuapan	Puebla	4.55
AGC_091	Chignahuapan	Puebla	4.54

7. Recomendaciones al equipo

- **Congelar** LightGBM con longitud + píxel climático + nitrógeno y edafología (RMSE 0.533) como candidato de entrega.
- Mantener un respaldo **solo reto** (mejor ~0.550 RMSE) por si el jurado prioriza no usar externos.
- No invertir más tiempo en barridos de 1024 tablas ni en más hiperparámetros: el margen ya es mínimo.
- Siguiendo paso de producto: empaquetar el modelo en *entrega/* y abrir el dashboard.
- Cuidado: algunos municipios tienen una sola parcela; su error individual es ruidoso.

Baselines de referencia — media global: 1.153 t/ha; media por estado: 1.084 t/ha. Informe técnico detallado: modelos/comparativas/superciclo_v1/informe_superciclo.html